

Detección de enfermedades en la hoja de tomate

1. Contexto de aplicación.

La agricultura de precisión, ha prometido revolucionar las prácticas agrícolas mediante el uso de tecnologías de monitoreo e intervención para aumentar la eficiencia de la producción y reducir los impactos ambientales. Las tecnologías de visión artificial que utilizan imágenes digitales para interpretar y comprender el mundo son capaces de proporcionar información precisa y específica del sitio sobre los cultivos y sus entornos. Hoy en día, la visión por computadora se ha utilizado ampliamente para apoyar las tareas de agricultura de precisión (también conocida como agrovisión), como el monitoreo y fenotipado de cultivos, el control de malezas, la cosecha, detección de enfermedades, forma y tamaño de la planta, etc.

Las enfermedades en los cultivos de tomate se pueden detectar observando las hojas, lo cual en la agricultura convencional se realizan personas que periódicamente realizan una inspección visual de los cultivos. Esto implica que para realizar una detección oportuna se debe hacer las inspecciones en pequeños periodos de tiempo, lo cual implica disponer de mucho personal. En la agricultura de precisión, la inspección visual se realiza mediante imágenes capturadas por drones y mediante el reconocimiento de imagen se detectan las enfermedades. Para esto, se requiere de un modelo capaz de reconocer las diferentes enfermedades que afectan a los diferentes tipos de cultivos. Este trabajo se enfoca en el reconocimiento de enfermedades en los cultivos de tomate.

2. Objetivo de machine learning

Este trabajo se enfoca en construir y entrenar un modelo capaz de reconocer, dada una imagen de planta de tomate, cual enfermedad presenta o si por lo contrario la planta esta saludable. Para esto se plantea un problema de clasificación.

3. Dataset

El Dataset utilizado fue tomado de la web <https://www.kaggle.com/> y consta de 11.000 imágenes (199 MB) de planta de tomate distribuidas de la siguiente forma:


- Datos de entrenamiento: 10.000 imágenes distribuidas en 10 clases, donde cada clase tiene asociada 1.000 imágenes.

- Datos de Validación: 1.000 imágenes distribuidas en 10 clases, donde cada clase tiene asociada 100 imágenes.



4. Métricas de desempeño


Utilizaremos la precisión como métrica de desempeño, entendiendo precisión como el número de elementos identificados correctamente como positivo de un total de elementos identificados como positivos.



5. Referencias y resultados previos

En la web <https://www.kaggle.com/> de donde se tomo la base de datos, podemos encontrar diferentes modelos aplicados al problema de detección de enfermedades de tomate.

- En <https://www.kaggle.com/code/adinishad/tomato-leaf-detection-by-transfer-learning> mediante transfer learning obtienen los siguientes resultados:



- En <https://www.kaggle.com/code/shakib23/tomato-leaf-disease-detection> obtienen los siguientes resultados:

